

استاد: دکتر احمد براآنی **دستیار**: الهام اسماعیلی

شماره دانشجویی: ۴۰۰۳۶۱۴۰۰۴

تمرین اول: فاز سوم پروژه سخنرانیهای TED درس: بازیابی پیشرفته اطلاعات نام و نام خانوادگی: سید عمید اسدالهی مجد


آدرس گنت: https://github.com/amidmajd/ted-talk-classification

یافتن برچسبهای سخنرانیها با استفاده از روش skip-gram


در فاز دوم پروژه با استفاده از روش skip-gram بردار مربوط به transcript هر سخنرانی ساخته شد. حال برای استفاده از این بردادها ده کلمه با بیشترین فرکانس به عنوان skip-gram.py داده میشود تا با استفاده از این بردادها ده کلمه با بیشترین فرکانس به عنوان برچسبهای هر سخنرانی در ایندکس موجود در الستیک سرچ ذخیره شوند. با فرض وجود داده های مربوط به سخنرانی ها در الستیک سرچ (حاصل فاز اول پروژه)، تغییرات زیر در فاز دوم پروژه برای اجرای فاز سوم پروژه انجام شدند.

در کد skip-gram.py در خط ۲۴ متغیر جدیدی با نام FastText تعریف می شود که شامل محل ذخیره متن سخنرانی به ازای هر الله است (برای ساخت بردار با استفاده از کتابخانه FastText نیاز است تا فایل متنی داشته باشیم). در ادامه در خط ۳۶، به ازای هر متن سخنرانی بردار مربوط به transcript ساخته می شود. سپس با فراخوانی model.words آرایه ای شامل کلمات سخنرانی به ترتیب فراوانی هرکلمه از مدل مربوط به بردارها دریافت می شود. پس از حذف کلمات مخنرانی به بیشترین فرکانس انتخاب می شوند. سپس هریک از داده های ایندکس شامل متن سخنرانی ها با افزودن فیلد جدیدی با نام labels که شامل برچسبهای بدست آمده است، آپدیت می شوند.

در شکلهای زیر نمونهای از خروجی حاصل از اجرای فایل skip-gram.py را مشاهده مینماییم.



یک سخنرانی بههمراه برچسبهای جدید اضافهشده به آن



یک سخنرانی بههمراه برچسبهای جدید اضافهشده به آن

تابع save_transcript_with_labels

در این تابع یک آرایه شامل اطلاعات خروجی الستیک و به فرمت مخصوص آن و همچنین نام فایل خروجی دریافت می شود. برای استفاده از classifier کتابخانه FastText باید یک فایل شامل خطوط متن داشته باشیم. هر خط از این فایل، مربوط به متن یک سخنرانی بوده و قبل از متن سخنرانی در هر خط برچسب های مربوط به آن سخنرانی ذخیره می شوند. به ابتدای برچسبها باید عبارت __label__ افزوده شود و باهم یک فاصله داشته باشند. در این تابع هر سخنرانی و برچسبهای مربوط به آن که در مرحله پیشین استخراج شدند از الستیک سرچ استخراج می شوند و در یک خط با فرمت ذکر شده ذخیره می شوند. دو متن سخنرانی به همراه برچسبهای مربوطه را می توان در شکل زیر مشاهده نمود. خروجی این تابع برای ذخیره داده های test و test به صورت جداگانه استفاده می شود.



بخشی از فایلهای test و train ساخته شده شامل برچسبهای هر transcript و متن آن

توضیح کد مربوط به دستهبندی سخنرانیها

در بدنهی اصلی کد با استفاده از تابع train_test_split از کتابخانه sklearn با نسبت ۹۰ به ۱۰ درصد دادهها به train_test و test تقسیم شدند. سپس با استفاده از تابع save_transcript_with_labels این دادهها با فرمت مربوطه با تحت عناوین test_data.txt و test_data.txt ذخیره شدند.

سپس با استفاده از تابع train_supervised از کتابخانه FastText و با ورودی train_data.txt به عنوان فایل آموزش، نرخ یادگیری برابر با ۱۰۲۵ مدل آموزش دیده و ساخته می شود. سپس مدل را با نام classifier_model.bin ذخیره می نماییم تا در آینده بتوان آن را بارگیری نمود و استفاده کرد. مقدار K در بخش test و test بیانگر تعداد بر چسبهای در خواستی از مدل جهت پیشبینی است.

در ادامه با فراخوانی تابع test با ورودی test_data.txt مقادیر precision و precision بدست آمدند و نمایش داده می شوند test بدست آمدند و نمایش داده می شوند (metals fuels برچسبهایی مثل metals fuels، fuels و سرا را با دقتهای نمایش داده شده در شکل زیر پیشبینی کرده است.

متن ورودی:

We currently have enough fossil fuels to progressively transition off of them, says climate campaigner Tzeporah Berman, but the industry continues to expand oil, gas and coal production and exploration. With searing passion and unflinching nerve, Berman reveals the delusions keeping true progress from being made and offers a realistic path forward: the Fossil Fuel Non-Proliferation Treaty.

```
Read 0M words

Number of words: 28134

Number of labels: 1967

Progress: 100.0% words/sec/thread: 362276 lr: 0.0000000 avg.loss: 3.085267 ETA: 0h 0m 0s

Example:
(('_label_fuels', '_label_metals', '_label_fossil', '_label_electricity', '_label_rocks', '_label_bananas', '_label_ban
```

خروجي کار به همراه precision و precall مدل ساختهشده (k=10) (precision برابر با ۷۳ درصد و recall برابر با ۱۰ درصد)

² Learning Rate

³ Epoch